

26-1 DSL 정규 세션

기초과제



- ☑ 본 과제는 「통계학입문」, 「통계방법론」 및 「수리통계학(1)」 일부 내용을 다루며, NumPy와 Pandas의 활용 연습을 돕기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트(?)를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하시어 해결해주시고요. 단, 답안 표절은 금지합니다.
- ☑ 서술형 문제는 ✍, 코딩 문제는 © 으로 표기가 되어 있습니다. 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 pdf로 제출해주시고 코드 문제들은 ipynb 파일에 답안을 작성하시어 제출해주시고요.
- ☑ 1/16 (금) 23시 59분까지 Github에 PDF 파일과 ipynb 파일을 zip 파일로 압축하여 제출해주시고요. Github에 제출하는 방법을 모른다면 학술부장에게 연락 부탁드립니다.

문제 1 (Weak) Law of Large Numbers

큰 수의 법칙은 표본 평균의 수렴성을 보장하는 법칙으로, 중심극한정리(CLT)와 더불어 통계학에서 중요한 법칙입니다. 예를 들어, 큰 수의 법칙은 몬테카를로(Monte Carlo) 방법론의 이론적 기반을 제공합니다. 이 문제에서는 큰 수의 약한 법칙의 정의를 확인하고, 이를 코드를 통해 확인해 보겠습니다.

1-1 ✍ : 큰 수의 약한 법칙(Weak Law of Large Numbers)의 정의를 서술하시고 증명하시오.

👉 Hogg(8판) 5장 1절

theorem: let X_1, \dots, X_n be i.i.d with $E(X_i) = \mu$, $Var(X_i) < \infty$ for $i = 1, \dots, n$
 the sample mean $\bar{X} = \frac{1}{n} \sum X_i$
 then, $\lim_{n \rightarrow \infty} Pr(|\bar{X} - \mu| < \epsilon) = 1$
 proof: since X_i 's are i.i.d $\Rightarrow E(\bar{X}) = E(\frac{1}{n} \sum X_i) = \frac{1}{n} E(\sum X_i) = \frac{1}{n} \cdot n \cdot \mu = \mu$.
 $Var(\bar{X}) = Var(\frac{1}{n} \sum X_i) = \frac{1}{n^2} Var(\sum X_i) = \frac{1}{n^2} \cdot n \sigma^2 = \frac{1}{n} \sigma^2$
 Putting this into Chebyshev's inequality $Pr(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$,
 $Pr(|\bar{X} - E(\bar{X})| \geq \epsilon) \leq Var(\bar{X}) / \epsilon^2$, $Pr(|\bar{X} - \mu| \geq \epsilon) \leq \sigma^2 / n \epsilon^2$
 $Pr(|\bar{X} - \mu| < \epsilon) \geq 1 - \sigma^2 / n \epsilon^2$, $\lim_{n \rightarrow \infty} Pr(|\bar{X} - \mu| < \epsilon) \geq \lim_{n \rightarrow \infty} (1 - \sigma^2 / n \epsilon^2) \geq 1 - \lim_{n \rightarrow \infty} \frac{\sigma^2 / \epsilon^2}{n} = 1$

1-2 © : NumPy를 이용하여 큰 수의 약한 법칙(WLLN)을 시뮬레이션으로 확인하시오.

문제 2 | Central Limit Theorem

중심극한정리는 확률변수의 합 형태 (Sum of Random Variables)의 극한분포를 손쉽게 구할 수 있도록 해 주기에 통계학에서 가장 자주 사용하는 정리입니다. 이 문제에서는 중심극한정리의 정의와 그 활용에 대해 짚어보겠습니다.

2-1 ✎ : 중심극한정리(Central Limit Theorem)의 정의를 서술하시오.

👉 통계학입문 (3 판) 7 장 참고

👉 Hogg(8 판) 4 장 2 절, 5 장 3 절 참고

If you have a large number of i.i.d random variables
from any dist with mean μ and variance σ^2 ,
the sample mean will approximately normally distributed as $n \rightarrow \infty$

2-2 ✎ : 중심극한정리가 통계적 추론 중 "구간추정"에서 어떻게 활용되는지 서술하시오.

👉 Hogg(8 판) 4 장 2 절

분포가 이항분포일 경우, n 가 충분히 클 때 이항분포는 정규분포로 근사할 수 있다.
분포가 포아송 분포일 경우, λ 가 충분히 클 때 포아송 분포는 정규분포로 근사할 수 있다.
정규분포에 대한 구간 추정은 다음과 같다.

2-3 © : NumPy 를 이용하여 중심극한정리(CLT)가 적용되는 과정을 확인하시오.

문제 3 모분산에 관한 추론

카이제곱 분포는 모집단의 모분산 추정에 유용하게 쓰이며, 정규분포에서의 랜덤표본에서 표본분산과 관계되는 분포입니다. 표준정규분포를 따르는 서로 독립인 확률변수 $Z_1, Z_2, Z_3, \dots, Z_k$ 가 있을 때, $V = Z_1^2 + Z_2^2 + Z_3^2 + \dots + Z_k^2 \Rightarrow V \sim$ 자유도가 k 인 χ^2 분포를 따른다고 할 수 있습니다. 대개 모분산에 관한 추론에 사용되며, 검정통계량으로 $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 가 쓰입니다.

3-1 : 플라스틱 판을 제조하는 공장이 있다. 판 두께의 표준편차가 1.5mm 를 넘으면 공정 상에 이상이 있는 것으로 간주합니다. 오늘 아침 10 개의 판을 무작위 추출하여 두께를 측정한 결과가 다음과 같았습니다.

{226, 228, 226, 225, 232, 225, 227, 229, 228,, 230}

해당 판 두께의 분포가 정규분포를 따른다고 할 때, 공정에 이상이 있는지를 검정하세요.

a) 귀무가설과 대립가설을 설정하시오.

H_0 : 판 두께의 표준편차가 1.5mm 는 넘지 않는다 ($\sigma \leq 1.5$)

H_1 : 판 두께의 표준편차가 1.5mm 는 넘는다, ($\sigma > 1.5$)

b) 유의수준 5%에서의 가설검정을 수행하고 판 두께의 분산에 대한 90% 신뢰구간을 구하시오.

어떤 검정통계량이 어떤 분포를 따르는지, 언제 귀무가설을 기각하는지 정해야 합니다.

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} = \frac{9 \times 3.15}{2.25} = 12.6 \quad S^2 = \frac{1}{10-1} \sum (x_i - \bar{x})^2 = 3.15$$

$$\chi^2_{0.95, 9} \approx 16.92$$

$$\chi^2 > \chi^2_{0.95, 9} \quad \text{이므로 } H_0 \text{ 기각}$$

$$CI: \left(\frac{(n-1)S^2}{\chi^2_{0.95, 9}}, \frac{(n-1)S^2}{\chi^2_{0.05, 9}} \right)$$

$$\rightarrow \left(\frac{9 \times 3.15}{16.92}, \frac{9 \times 3.15}{4.167} \right)$$

$$\rightarrow (2.13, 11)$$

문제 4 통계적 방법론

t 검정은 모집단이 정규분포를 따르지만 모표준편차를 모를 때, 모평균에 대한 가설검정 방법입니다. 대개 두 집단의 모평균이 서로 차이가 있는지 파악하고자 할 때 사용하며, 표본평균의 차이와 표준편차의 비율을 확인하여 통계적 결론을 도출합니다. ANOVA Test의 경우 집단이 2 개보다 많은 경우 모평균에 차이가 있는지 파악하고자 할 때 사용되며, 이것은 코드로만 살펴보겠습니다.

4-1 : 어떤 학우가 DSL 학회원(동문 포함)의 평균 키가 DSL 학회원이 아닌 사람의 평균 키보다 크다고 주장하여, 실제로 그러한지 통계적 검정을 수행하려고 합니다. 며칠간 표본을 수집한 결과 다음과 같은 값을 얻었습니다.

표본 수: 총 250 명, 각 125 명
측정에 응한 DSL 학회원들의 평균 키 : 173.5cm / 표준편차 : 7.05cm
측정에 응한, DSL 학회원이 아닌 사람들의 평균 키 : 171.4cm / 표준편차 : 7.05cm

a) 귀무가설과 대립가설을 설정하시오.

H_0 : DSL 학회원의 평균 키가 DSL 학회원이 아닌 사람의 평균 키보다 작거나 같다.
 H_1 : DSL 학회원의 평균 키가 DSL 학회원이 아닌 사람의 평균 키보다 크다

b) 유의수준 5%에서의 가설검정을 수행하고 결론을 도출하시오. (단, 키는 정규분포를 따르며 각 집단의 분산은 같다고 가정한다.)

통계학입문(3 판) 7 장 참고
어떤 검정통계량이 어떤 분포를 따르는지, 언제 귀무가설을 기각하는지 정해야 합니다.

$$\bar{x}_1 = 173.5 \quad \bar{x}_2 = 171.4 \quad s_E = \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} = 1.05 \sqrt{\frac{n}{125}} \approx 0.892$$

$$s_1 = s_2 = 1.05$$

$$t = \frac{\bar{x}_1 - \bar{x}_2}{s_E} = \frac{173.5 - 171.4}{0.892} \approx 2.35 > t_{0.95, 248} \approx 1.65$$

4-2 : 한 학우가 이번에는 각 학회의 평균 키가 똑같다는 주장을 하였습니다. 해당 학우가 제공한 ESC 학회의 학회원별 키 데이터를 활용해 가설검정을 진행하고자 합니다. 데이터는 heights.csv 파일에 저장되어 있습니다.

a) 귀무가설과 대립가설을 설정하시오.

H_0 : 각 학회의 평균 키가 똑같다.
 H_1 : 각 학회의 평균 키가 하나라도 작거나 다르다.

b) 파이썬의 scipy.stats 을 활용해서 유의수준 5%에서의 가설검정을 수행하고 결론을 도출하시오. 결론은 .ipynb 파일에 쓰셔도 괜찮습니다.

One-way Anova Test 를 활용해서 사용하는 문제입니다.
활용해야 될 함수는 scipy.stats.f_oneway 입니다.

문제 5 NumPy + Pandas 활용

기초과제.ipynb 파일에 제공된 문제들을 참고하여 수행하시기 바랍니다.

Reference

- 통계학입문(3 판, 강상욱 외)
- Introduction to Mathematical Statistics(8 판, Hogg et.al)
- 23-2 기초과제 1 (9 기 이성균)
- 24-1 기초과제 1 (10 기 신재우)
- 24-2 기초과제 1 (11 기 김현진, 김정우)
- 25-1 기초과제 1 (12 기 이정우)
- 25-2 기초과제 1 (13 기 강승우)

Data Science Lab

담당자: 14 기 박창용

gkrckddyd0@yonsei.ac.kr